Лабораторная работа № 4.

Проверка статистических гипотез о виде и параметрах распределения случайных величин

Цель работы: Приобретение практических навыков последовательного выбора и применения параметрических и непараметрических критериев для проверки одновыборочных, двухвыборочных (зависимых и независимых) и многовыборочных гипотез.

Исходные данные: Статистические сборники Федеральной службы государственной статистики (Росстата), представленные в файле CHISLO_DOCTORS.xlsx.

Задание и порядок выполнения

Часть I.

1. **Формирование выборочных совокупностей**
   - На основе данных файла CHISLO_DOCTORS.xlsx выделите выборку значений случайного показателя X — **«Число врачей на 10 тысяч человек населения»** для субъектов РФ, входящих в состав Федерального округа (ФО), указанного в вашем варианте.
   - Сформируйте аналогичные выборки для каждого года из заданного временного периода T: **2005, 2010, 2015, 2019, 2020 и 2021 гг.** Объектами наблюдения (элементами выборки) должны являться конкретные регионы, составляющие округ.
2. **Первичный статистический и визуальный анализ**
   - Для каждого года из периода T осуществите графический анализ эмпирического распределения показателя X в исследуемом Федеральном округе. Постройте гистограммы и диаграммы размаха (боксплоты / «ящики с усами»).
   - Рассчитайте показатели описательной статистики для каждого временного сечения: выборочное среднее, выборочное стандартное отклонение и медиану, а также выборочные коэффициенты асимметрии и эксцесса.
     Для каких лет из периода T можно ожидать, что распределение показателя X в исследуемом Федеральном округе окажется нормальным?
3. **Проверка гипотезы о законе распределения**
   - Сформулируйте нулевую гипотезу о подчинении исследуемого показателя X в Федеральном округе нормальному закону распределения (отдельно для каждого года).
   - Проверьте гипотезу с помощью **критерия Шапиро — Уилка** на уровне значимости α, указанном в вашем варианте. Сделайте статистический вывод, определяющий дальнейший ход исследования: выбор между параметрическими и непараметрическими методами на последующих этапах.
4. **Сравнение показателей с округом-соседом (анализ двух независимых выборок)**

- Сформируйте выборку из значений показателя X для субъектов РФ, входящих в состав соседнего Федерального округа (в соответствии с вашим вариантом), за аналогичный период T. Проверьте распределение показателя во второй выборке на нормальность с помощью критерия Шапиро — Уилка.
- Сформулируйте нулевую гипотезу об отсутствии значимых различий между уровнями обеспеченности врачами в двух округах. В качестве альтернативы выберите или гипотезу со знаком “>”, или гипотезу со знаком “<”.

Выбор статистического критерия:

- **Параметрический анализ:** Если в *обеих* выборках (исследуемого округа и округа-соседа) закон распределения признан **нормальным**, примените **t-критерий Стьюдента для независимых выборок**. Предварительно проверьте гипотезу **о равенстве выборочных дисперсий**. При равенстве дисперсий используйте классический t-тест, при их неравенстве — **t-критерий Уэлча**.
- **Непараметрический анализ:** Если хотя бы в *одной* из двух выборок закон распределения признан **отличным от нормального**, примените непараметрический **U-критерий Манна — Уитни** для двух независимых выборок.

Сделайте статистические выводы на уровне значимости α для каждого года.

5. **Анализ внутрирегиональной динамики (анализ двух зависимых выборок)**
   - Сопоставьте показатели одних и тех же субъектов РФ исследуемого Федерального округа в разные временные периоды (пары лет для сравнения указаны в варианте).
   - Сформулируйте гипотезы об отсутствии значимых изменений в уровне обеспеченности врачами между двумя периодами.
   - Вычислите вектор попарных разностей для каждого субъекта округа. Проверьте полученный вектор разностей на нормальность критерием Шапиро — Уилка.
   - **Выбор статистического критерия:**
   - **Параметрический анализ:** Если распределение попарных разностей D **существенно не отличается от нормального**, примените парный **t-критерий Стьюдента для зависимых выборок**.
   - **Непараметрический анализ:** Если закон распределения разностей D **отклоняется от нормального**, примените парный **критерий знаковых рангов Уилкоксона для связных выборок**.
   - Примите статистическое решение на уровне значимости α. Сформулируйте содержательный экономико-статистический вывод о динамике кадровой обеспеченности в округе.
6. **Сравнение показателей Федерального округа с общероссийским уровнем (одновыборочный анализ)**
   - Сформулируйте нулевую и одностороннюю альтернативную гипотезы для проверки гипотезы о том, что уровень обеспеченности врачами в заданном Федеральном округе значимо отличается (выше или ниже) от общероссийского значения.

Значения показателя X по Российской Федерации в целом извлеките из файла CHISLO_DOCTORS.xlsx.

Выбор статистического критерия:

- Если в пункте 3 гипотеза о нормальности распределения выборки **не была отвергнута**, примените параметрический **одновыборочный t-критерий Стьюдента** для соответствующей односторонней альтернативы.
  Значения показателя X по Российской Федерации в целом извлеките из файла CHISLO_DOCTORS.xlsx.

Часть II.

Выбор статистического критерия:

- Если в пункте 3 распределение признано **отличным от нормального**, то для проверки гипотезы о том, что уровень обеспеченности врачами в заданном Федеральном округе значимо отличается (выше или ниже) от общероссийского уровня примените непараметрический **критерий знаковых рангов Уилкоксона** для одной выборки.
- Проведите расчеты на уровне значимости α и сделайте статистический вывод.

7. **Сравнение уровня обеспеченности врачами между макрорегионами РФ (однофакторный статистический анализ)**

- Выберите три Федеральных округа (в соответствии с вашим вариантом) и сформируйте пространственную выборку значений показателя обеспеченности врачами по всем входящим в них регионам за фиксированный год (в соответствии с вашим вариантом).
- Сформулируйте нулевую гипотезу о том, что распределения показателя X во всех трех Федеральных округах одинаковы (макрорегионы статистически однородны).
- Примените непараметрический **критерий Краскела — Уоллиса**, который позволяет сравнивать три группы без обязательного выполнения условий нормальности и равенства дисперсий. На основе анализа величины p-value сделайте статистический вывод на уровне значимости α.
- **Визуальный анализ:** Постройте совмещенную диаграмму размаха («ящики с усами») для этих трех округов. Если критерий Краскела — Уоллиса зафиксировал наличие значимых различий, на основе графиков определите, какой из округов демонстрирует наиболее сильное отклонение медианного уровня от остальных.

УКАЗАНИЕ: Более подробную информацию о параметрических и непараметрических критериях см. по ссылкам:

https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_1samp.html#scipy.stats.ttest_1samp

https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_rel.html#scipy.stats.ttest_rel

https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_ind.html#scipy.stats.ttest_ind

https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.levene.html#scipy.stats.levene

https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.bartlett.html#scipy.stats.bartlett

https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.wilcoxon.html#scipy.stats.wilcoxon

https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.mannwhitneyu.html#scipy.stats.mannwhitneyu

https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.kruskal.html#scipy.stats.kruskal

Контрольные вопросы для защиты лабораторной работы

1. Какую роль играет критерий Шапиро — Уилка в данной лабораторной работе? Как его результат влияет на дальнейший выбор методов анализа?
2. В чем разница между параметрическими и непараметрическими статистическими критериями? Назовите по одному примеру из вашей работы.
3. В пункте 6 (сравнение с общероссийским значением) мы использовали односторонние альтернативные гипотезы, а в пункте 4 (сравнение с округом-соседом) — двусторонние. На что это влияет при вызове теста в Python?
4. Чем t-критерий Уэлча отличается от классического t-критерия Стьюдента для двух независимых выборок? В каком случае программа автоматически (или по вашему указанию) выбирает тест Уэлча?
5. В пункте 5 (анализ динамики) мы проверяли на нормальность сами выборки по годам или что-то другое? Почему этот шаг отличается от анализа независимых выборок в пункте 4?
6. Что проверяет «глобальный» критерий Краскела — Уоллиса в пункте 7? Если этот критерий показал p-value меньше уровня значимости α, о чем это говорит и как сделать выводы без проведения дополнительных сложных тестов?
7. Что такое p-value? Сформулируйте универсальное правило принятия или отклонения нулевой гипотезы на основе p-value и заданного уровня значимости α.

№ вар.	Исследуемый ФО (п. 1 - 6)	Округ-сосед (п. 4)	Пара лет (п. 5)	Три округа для анализа; год для анализа (п. 7)	Уровень знач. α
1	ЦФО	ПФО	2005 и 2021	ЦФО, ПФО, СЗФО;	0.025

				2019	
2	ЦФО	СЗФО	2010 и 2021	ЦФО, СЗФО, ЮФО; 2021	0.01
3	ЦФО	ЮФО	2015 и 2021	ЦФО, ПФО, ЮФО; 2010	0.03
4	СЗФО	ЦФО	2005 и 2020	СЗФО, ЦФО, ПФО; 2015	0.04
5	СЗФО	ПФО	2010 и 2020	СЗФО, ПФО, УФО; 2020	0.015
6	СЗФО	УФО	2015 и 2020	СЗФО, ЦФО, УФО; 2005	0.06
7	ПФО	ЦФО	2005 и 2019	ПФО, ЦФО, СЗФО; 2019	0.05
8	ПФО	СЗФО	2010 и 2019	ПФО, СЗФО, УФО; 2020	0.07
9	ПФО	ЮФО	2015 и 2019	ПФО, ЮФО, СКФО; 2021	0.05
10	ПФО	УФО	2005 и 2021	ПФО, УФО, СФО; 2015	0.08
11	ЮФО	ЦФО	2010 и 2021	ЮФО, ЦФО, ПФО; 2010	0.02
12	ЮФО	ПФО	2015 и 2021	ЮФО, ПФО, СКФО; 2021	0.03
13	ЮФО	СКФО	2005 и 2020	ЮФО, СКФО, ЦФО; 2020	0.09
14	СКФО	ЮФО	2010 и 2020	СКФО, ЮФО, ПФО; 2019	0.02
15	СКФО	ЮФО	2015 и 2020	СКФО, ЮФО, ЦФО; 2010	0.05
16	УФО	СЗФО	2005 и 2019	УФО, СЗФО, ПФО; 2005	0.06

17	УФО	ПФО	2010 и 2019	УФО, ПФО, СФО; 2010	0.03
18	УФО	Сибирский ФО	2015 и 2019	УФО, СФО, ДФО; 2015	0.04
19	Сибирский ФО	УФО	2005 и 2021	СФО, УФО, ПФО; 2019	0.05
20	Сибирский ФО	ДФО	2010 и 2021	СФО, ДФО, УФО; 2020	0.01
21	ДФО	Сибирский ФО	2015 и 2021	ДФО, СФО, УФО; 2021	0.075
22	ЦФО	ПФО	2010 и 2020	ЦФО, ПФО, ЮФО; 2005	0.025
23	СЗФО	УФО	2005 и 2021	СЗФО, УФО, СФО; 2010	0.01
24	ПФО	УФО	2015 и 2020	ПФО, УФО, СФО; 2015	0.075
25	ЮФО	СКФО	2010 и 2019	ЮФО, СКФО, ПФО; 2019	0.025
26	СЗФО	УФО	2015 и 2020	ПФО, УФО, СФО; 2015	0.05
27	СЗФО	УФО	2005 и 2021	СЗФО, УФО, СФО; 2010	0.025
28	Сибирский ФО	ДФО	2005 и 2020	СФО, ДФО, УФО; 2020	0.02
29	ДФО	Сибирский ФО	2010 и 2020	ДФО, СФО, УФО; 2015	0.045
30	ЦФО	ПФО	2005 и 2021	ЦФО, ПФО, ЮФО; 2015	0.03
31	СКФО	ЮФО	2015 и 2021	ЮФО, СКФО, ПФО; 2010	0.05

30	Сибирский ФО	ДФО	2015 и 2020	СФО, ДФО, УФО; 20050	0.04
33	ЮФО	СКФО	2005 и 2010	ЮФО, СКФО, ПФО; 2015	0.025

Требования к структуре и оформлению отчета по лабораторной работе

Отчет выполняется должен содержать следующие обязательные разделы:

1. **Титульный лист** номера лабораторной работы, ФИО студента, номера группы и номера варианта.
2. **Введение и постановка задачи**
   - Краткое описание цели работы.
   - Четкое указание параметров своего варианта: исследуемый ФО, округ-сосед, три округа для пункта 7, исследуемые пары лет, уровень значимости α.
3. **Основная часть (по пунктам задания)**
   - **Пункт 1–2:** Сводная таблица с рассчитанными показателями описательной статистики за все годы. Графический материал (гистограммы и боксплоты должны быть подписаны, иметь оси с названиями и легенду).
   - **Пункт 3:** Таблица с результатами проверки на нормальность (значение статистики критерия Шапиро — Уилка, полученное p-value и явный вывод: *распределение является нормальным / распределение отлично от нормального*).
   - **Пункты 4–6:** По каждому пункту должны быть приведены:
     - Формулировка нулевой H_0 и альтернативной H_1 гипотез.
     - Обоснование выбора критерия (со ссылкой на результаты проверки нормальности или равенства дисперсий Левена).
     - Результаты расчетов (значение статистики теста и p-value).
     - Статистическое решение (*принять* H_0 */ отвергнуть* H_0).
   - **Пункт 7:** Результаты критерия Краскела — Уоллиса, совмещенный боксплот трех округов и его краткий аналитический разбор.
4. **Заключение**
   - Итоговый аналитический вывод (3–4 абзаца). Следует обобщить результаты и ответить на содержательный вопрос: как изменилась обеспеченность врачами в федеральном округе за 15 лет, сильно ли она отличается от общероссийского уровня, округов-соседей и других макрорегионов страны.
5. **Приложение** (в конце отчета прикрепляется полный листинг написанного кода на Python).